

ЧАСТЬ 1: BUSINESS KPIs (БИЗНЕС-МЕТРИКИ)

Удержание (Retention)

Что измеряет: Доля пользователей, вернувшихся к продукту через заданное время после первого визита.

Формула:

$$\text{Retention}(Dn) = \frac{\text{Пользователи, активные в день } n}{\text{Пользователи, пришедшие в день } 0} \times 100\%$$

Целевые значения (ориентир):

- ИИ-чат / ассистент: D1: 40-60% | D7: 20-35% | D30: 10-20%
- ИИ-инструмент для бизнеса: D30: 30-50%

Как интерпретировать:

- Рост → продукт становится ценнее со временем
- Падение → возможно, модель деградирует или пользователи разочаровались в качестве ответов

Действия при отклонении:

- ☐ Проверить качество ответов модели за период
- ☐ Провести опрос оттокших пользователей
- ☐ Протестировать новую версию модели / фичу

Конверсия (Conversion)

Что измеряет: Доля пользователей, выполнивших целевое действие (покупка, подписка, активация).

Формула:

$$\text{Conversion} = \frac{\text{Пользователи, совершившие целевое действие}}{\text{Пользователи, начавшие путь к действию}} \times 100\%$$

Типы конверсий для ИИ-продуктов:

- В триал: регистрация → первый запрос к ИИ
- В оплату: триал → покупка подписки
- В активацию: первый запрос → регулярное использование

Целевые значения (ориентир):

- Конверсия в триал: 20-40%
- Конверсия в оплату: 5-15% (зависит от цены и ниши)

Как интерпретировать:

- Низкая конверсия в триал → проблема в онбординге / ценности
- Низкая конверсия в оплату → проблема в качестве ИИ / цене

LTV (Lifetime Value)

Что измеряет: Ожидаемая выручка от одного пользователя за всё время использования продукта.

Формула (упрощённая):

$LTV = (\text{Средний чек}) \times (\text{Частота покупок}) \times (\text{Средний срок жизни})$

Для подписочной модели:

$LTV = (ARPU) \times (1 / \text{Churn Rate})$

где: ARPU — средняя выручка на пользователя в месяц
Churn Rate — месячный процент оттока

Целевые значения:

- Минимальный LTV: $> 3 \times \text{CAC}$ (стоимость привлечения клиента)
- Оптимальный: $5-10 \times \text{CAC}$

Как использовать:

- Для расчёта допустимого CAC в маркетинге
- Для оценки эффективности удержания и монетизации

⚙ ЧАСТЬ 2: ML METRICS (МЕТРИКИ МОДЕЛИ)

◆ Точность (Accuracy)

Что измеряет: Доля правильных предсказаний модели.

Формула:

$\text{Accuracy} = (TP + TN) / (TP + TN + FP + FN)$

где: TP — True Positive, TN — True Negative
FP — False Positive, FN — False Negative

Когда использовать:

- Сбалансированные датасеты (классы примерно равны по объёму)
- Когда стоимость ошибки одинакова для всех классов

Ограничения:

- Вводит в заблуждение при дисбалансе классов
- Не показывает, какие именно ошибки делает модель

◆ Точность и Полнота (Precision / Recall)

Precision (Точность):

«Сколько из предсказанных положительных — действительно +?»

Формула: $\text{Precision} = TP / (TP + FP)$

Recall (Полнота):

«Сколько из реальных положительных мы нашли?»

Формула: $\text{Recall} = TP / (TP + FN)$

Когда что важнее:

- Высокий Precision нужен, когда дорог «ложный срабатывание»:
→ Модерация контента, медицинская диагностика
- Высокий Recall нужен, когда дорог «пропуск»:
→ Поиск мошенничества, обнаружение угроз

Баланс: используйте F1-score

$F1 = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$

→ Единая метрика, когда важны оба параметра

◆ Drift (Дрейф данных / модели)

Что измеряет: Изменение распределения входных данных или предсказаний модели со временем.

Типы дрейфа:

- Data Drift: изменилось распределение входных признаков
- Concept Drift: изменилась связь «признаки → целевая переменная»

Методы детекции:

- Статистические тесты: Колмогорова-Смирнова, PSI
- Мониторинг распределений: гистограммы, средние, дисперсии
- Машинное обучение: детектор дрейфа на основе классификатора

Порог срабатывания алерта:

- Рекомендуемый: изменение метрики > ____% за ____ дней
- Или: статистическая значимость изменения при $\alpha = 0.05$

Действия при детекции дрейфа:

1. Проверить качество входных данных (не сломался ли пайплайн)
2. Проанализировать, какие признаки изменились
3. Принять решение: ☐ Ретренинг ☐ Адаптация ☐ Пересборка

ЧАСТЬ 3: OPERATIONAL METRICS (ОПЕРАЦИОННЫЕ МЕТРИКИ)

Latency (Время ответа)

Что измеряет: Время от получения запроса до выдачи ответа.

Ключевые метрики:

- P50 (медиана): _____ мс — «типичный» пользователь
- P95: _____ мс — «медленные» 5% запросов
- P99: _____ мс — «очень медленные» 1% запросов

Целевые значения (ориентир):

- Чат-бот / ассистент: P95 < 2000 мс
- Поисковая / рекомендательная фиша: P95 < 500 мс
- Пакетная обработка: не критично, но < 30 сек

Как оптимизировать:

- Кэширование частых запросов
- Оптимизация модели: квантование, прунинг, дистилляция
- Асинхронная обработка для долгих задач

Error Rate (Процент ошибок)

Что измеряет: Доля запросов, завершившихся ошибкой.

Типы ошибок для отслеживания:

- Ошибки инфраструктуры: таймауты, 5xx, недоступность сервиса
- Ошибки модели: исключения при инференсе, неверный формат
- Ошибки валидации: некорректный входной запрос пользователя

Формула:

$$\text{Error Rate} = \frac{\text{Количество ошибочных запросов}}{\text{Общее количество запросов}} \times 100\%$$

Целевые значения:

- Критические ошибки (5xx): < 0.1%
- Ошибки модели / валидации: < 2-5% (зависит от сложности)

Действия при превышении порога:

1. Автоматический алерт в канал мониторинга
2. Быстрый анализ: инфраструктура / модель / входные данные

3. При необходимости: откат на стабильную версию модели

◆ Uptime (Доступность)

Что измеряет: Доля времени, когда сервис доступен для обработки запросов.

Формула:

$$\text{Uptime} = (\text{Время доступности}) / (\text{Общее время}) \times 100\%$$

Целевые значения (ориентир):

- 99.0% («два девятки»): ~3.65 дней простоя в год
- 99.9% («три девятки»): ~8.76 часов простоя в год
- 99.99% («четыре девятки»): ~52 минуты простоя в год

Как измерять:

- Внешние мониторы: Ping, HTTP-запросы с разных локаций
- Внутренние метрики: health-check эндпоинты, readiness-probes

План обеспечения высокой доступности:

- ☐ Репликация сервисов в нескольких зонах доступности
- ☐ Автоматическое масштабирование при нагрузке
- ☐ Резервное копирование моделей и конфигураций
- ☐ План аварийного восстановления (DRP)

📄 СВОДНЫЙ ДАШБОРД МЕТРИК (заполнять еженедельно)

Неделя: _____ | Дата: ____/____/____

Бизнес-метрики:

- Retention D7: _____% (цель: ____%) Δ: ____ п.п.
- Конверсия в оплату: _____% (цель: ____%) Δ: ____ п.п.
- LTV: _____ руб. (цель: _____ руб.) Δ: _____ руб.

Метрики модели:

- Accuracy / F1: _____% (цель: ____%) Δ: ____ п.п.
- Precision: _____% • Recall: _____%
- Drift detected: ☐ Да ☐ Нет Если да: _____

Операционные метрики:

- Latency P95: _____ мс (цель: < ____ мс)
- Error Rate: _____% (цель: < ____%)
- Uptime: _____% (цель: > ____%)

● Критические инциденты за неделю:

1. _____
2. _____

□ План действий на следующую неделю:

1. _____
2. _____
3. _____

Подпись: _____ | Дата: ____/____/____

📝 Примечание: Храните историю метрик минимум 12 месяцев для анализа трендов. Используйте цветовую индикацию: □ в цели, □ близко к цели, ● отклонение.